

Support de présentation — Air Paradis Sentiment Analysis

Laureenda Demeule — Projet OC P7 — Soutenance

Slide 1 — Contexte

- Client : Air Paradis (compagnie aérienne)
 - Besoin : prédire le sentiment d'un tweet (positif / négatif)
 - Données : Sentiment140 (1,6M tweets, open source)
 - Livrable : prototype MLOps déployé sur le cloud
-

Slide 2 — Méthodologie globale

1. EDA + nettoyage (01_Analyse_Exploratoire.ipynb)
2. Trois approches de modélisation
3. Tracking MLflow
4. Sélection du meilleur modèle
5. Déploiement API Azure + monitoring App Insights

Split des données : **60 % train / 20 % validation / 20 % test**

Slide 3 — Approche 1 : Modèles simples

- TF-IDF (5000 features)
- Régression logistique : F1 test ~76,4 % (50k)
- Random Forest : F1 test ~72,5 %

Avantages : rapide, léger, interprétable. Utilisé en production sur Azure F1.

Slide 4 — Approche 2 : Deep Learning

- CNN-LSTM hybride
- Embeddings : Word2Vec vs GloVe
- Early stopping sur validation

Word2Vec ~65,7 % F1, GloVe ~69,4 % F1 sur 50k tweets.

Slide 5 — Approche 3 : BERT

- DistilBERT fine-tuned
- 2 epochs, échantillon stratifié 50k
- **Meilleur modèle entraîné : 81,5 % test accuracy, 81,5 % F1**

Sélectionné comme modèle de référence ; fallback logistic sur Azure F1 (mémoire).

Slide 6 — Comparaison MLflow

Modèle	Test F1
LogReg	76,4 %
Random Forest	72,5 %
CNN-LSTM W2V	65,7 %
CNN-LSTM GloVe	69,4 %
DistilBERT	81,5 %




Figure 1: Comparaison MLflow

MLflow — Experiment runs (50k sample)

Run name	Approach	Val F1	Test Acc	Test F1
tfidf_logistic		76.9%	76.4%	76.4%
tfidf_random_forest		72.5%	70.9%	72.5%
cnn_lstm_word2vec		64.9%	67.7%	65.7%
cnn_lstm_glove		68.5%	71.4%	69.4%
distilbert_finetuned		80.2%	81.5%	81.5%

Figure 2: MLflow UI — runs

Slide 7 — MLOps : principes

- **Tracking** : MLflow (params, metrics, artifacts)
- **Versioning** : Git + GitHub
- **Tests** : pytest (11 tests)
- **CI/CD** : GitHub Actions
- **Monitoring** : Azure Application Insights




Figure 3: GitHub Actions CI

Slide 8 — Mise en production

- API FastAPI : /predict, /health, /feedback
- Déploiement : Azure Web App F1
- Modèle déployé : `cnn_lstm_glove` (Modèle sur mesure avancé — 5 Mo)
- DistilBERT = meilleur modèle entraîné, trop lourd pour F1 (~250 Mo)
- Fallback automatique : `tfidf_logistic` si TensorFlow indisponible

Slide 9 — Interface Streamlit

- Saisie tweet → appel API cloud → prédiction
- Validation utilisateur (Oui / Non)
- Trace App Insights si erreur
- Alerte : 3 erreurs / 5 min




Figure 4: API Azure /health




Figure 5: Streamlit

Slide 10 — Suivi production

- Traces : texte, prédiction, timestamp
- Alertes configurées dans App Insights
- Boucle d'amélioration : collecte → analyse → réentraînement → MLflow compare → promotion




Figure 6: Application Insights

Slide 11 — Démonstration live

1. Tweet positif → prédiction positive
2. Tweet négatif → prédiction négative
3. Feedback incorrect → trace App Insights
4. GitHub Actions vert (11 tests)

Slide 12 — Conclusion

- DistilBERT = meilleur modèle entraîné (81,5 % F1)
- CNN-LSTM + GloVe = modèle sur mesure avancé déployé (69,4 % F1, 5 Mo)
- MLOps opérationnel (tracking, CI, monitoring, alertes)
- Piste d'évolution : données augmentées via feedback App Insights, active learning

Annexes pour l'évaluateur

- Repo : https://github.com/molly-muffin/P7_OC_AirParadis
- API : <https://air-paradis-sentiment-P7.azurewebsites.net>
- Notebooks : `notebooks/`
- Blog : `blog/article_mlops_sentiment.md`
- Commandes : voir `README.md`